Survey về Bảo mật dữ liệu nhạy cảm và Học máy bảo toàn quyền riêng tư

Nhóm 3

Ngày 20 tháng 3 năm 2026

1 Introduction

Sự phát triển của các hệ thống AI, đặc biệt trong lĩnh vực y tế và sức khỏe tâm thần, đã mở ra khả năng phân tích và khai thác dữ liệu bệnh nhân với độ chính xác cao. Tuy nhiên, các mô hình này thường yêu cầu truy cập vào dữ liệu nhạy cảm như hồ sơ bệnh án và transcript trị liệu, làm gia tăng nguy cơ rò rỉ thông tin cá nhân [1]. Trong bối cảnh đó, bài toán quan trọng không chỉ là cải thiện hiệu năng mô hình mà còn là đảm bảo quyền riêng tư cho dữ liệu lâm sàng.

Học liên hiệp (Federated Learning) được đề xuất như một giải pháp cho phép huấn luyện mô hình trên dữ liệu phân tán mà không cần chia sẻ dữ liệu gốc, từ đó giảm thiểu rủi ro vi phạm quyền riêng tư [2]. Tuy nhiên, các nghiên cứu cho thấy ngay cả khi không truy cập dữ liệu trực tiếp, mô hình vẫn có thể làm lộ thông tin thông qua các tấn công như membership inference [3].

Để giải quyết vấn đề này, quyền riêng tư vi phân (Differential Privacy) cung cấp một cơ chế bảo vệ mạnh mẽ bằng cách giới hạn ảnh hưởng của từng cá nhân trong quá trình huấn luyện, tiêu biểu là thuật toán DP-SGD với kỹ thuật clipping và thêm nhiễu Gaussian [4]. Song song đó, các phương pháp khử định danh (de-identification) trong clinical NLP được sử dụng để loại bỏ thông tin định danh cá nhân khỏi văn bản y tế trước khi xử lý [5, 6].

Ngoài ra, việc áp dụng các quy định như HIPAA trong annotation dữ liệu lâm sàng cho thấy việc bảo vệ quyền riêng tư không chỉ dừng lại ở việc loại bỏ thông tin trực tiếp mà còn cần xử lý các ngữ cảnh có thể dẫn đến tái định danh [7]. Bên cạnh các giải pháp kỹ thuật, các yếu tố về đạo đức và quản trị dữ liệu cũng đóng vai trò quan trọng trong việc triển khai AI trong môi trường lâm sàng [8].

Trong bài báo này, chúng tôi khảo sát các phương pháp bảo vệ quyền riêng tư trong AI, tập trung vào học liên hiệp, differential privacy và khử định danh dữ liệu lâm sàng, đồng thời phân tích các rủi ro và đề xuất hướng giảm thiểu phù hợp.

2 Literature Review

2.1 Rieke et al. (2020) [1]

Paper title:
Nicola Rieke et al., *The Future of Digital Health with Federated Learning*
Problem:
Dữ liệu y tế hiện nay bị phân tán trong các "data silos", gây hạn chế cho việc phát triển các mô hình AI mạnh. Đồng thời, việc chia sẻ dữ liệu giữa các tổ chức gặp nhiều rào cản pháp lý và đạo đức liên quan đến quyền riêng tư.
Method:
Bài báo là một survey tổng hợp các phương pháp Federated Learning trong y tế, phân tích từ kiến trúc hệ thống, quy trình huấn luyện cho đến các thách thức triển khai như communication cost và heterogeneity.
Key idea:
FL cho phép nhiều tổ chức cùng huấn luyện một mô hình chung mà không cần chia sẻ dữ liệu thô. Tuy nhiên, tác giả cũng nhấn mạnh rằng FL cần kết hợp thêm các kỹ thuật như secure aggregation hoặc differential privacy để tăng mức độ bảo mật.
Key equation:

$$w_{t+1} = \sum_k \frac{n_k}{n} w_k \tag{1}$$

Results:
Bài báo tổng hợp nhiều nghiên cứu cho thấy FL đã được áp dụng thành công trong các bài toán y tế như chẩn đoán hình ảnh và phân tích dữ liệu bệnh nhân. Tuy nhiên, vẫn tồn tại nhiều thách thức trong triển khai thực tế.
Relevance to our work:
Bài này giúp định hướng kiến trúc tổng thể cho hệ thống AI trong bài của nhóm. Nó cũng cung cấp cơ sở lý thuyết để kết hợp FL với các kỹ thuật bảo vệ quyền riêng tư khác.

2.2 Sheller et al. (2019) [2]

Paper title:
Micah J. Sheller et al., *Multi-Institutional Deep Learning Modeling Without Sharing Patient Data*
Problem:
Bài toán đặt ra là làm thế nào để huấn luyện mô hình AI trên dữ liệu y tế phân tán giữa nhiều bệnh viện mà không cần chia sẻ dữ liệu bệnh nhân. Trong thực tế, các quy định bảo mật như HIPAA khiến việc tập trung dữ liệu gần như không khả thi, đặc biệt với dữ liệu nhạy cảm như hồ sơ tâm lý.
Method:
Tác giả áp dụng Federated Learning, trong đó mỗi cơ sở huấn luyện mô hình cục bộ trên dữ liệu riêng của mình. Sau đó, các tham số mô hình được gửi lên máy chủ trung tâm để tổng hợp bằng thuật toán FedAvg, thay vì gửi dữ liệu thô.
Key idea:
Ý tưởng chính là "đưa mô hình đến dữ liệu thay vì đưa dữ liệu đến mô hình". Điều này giúp bảo vệ dữ liệu nhạy cảm tại nguồn, đồng thời vẫn tận dụng được dữ liệu từ nhiều tổ chức khác nhau.
Key equation:

$$w_{t+1} = \sum_{k=1}^{K} \frac{n_k}{n} w_t^{(k)} \tag{2}$$

Results:
Kết quả thực nghiệm cho thấy mô hình FL đạt hiệu năng gần tương đương với mô hình huấn luyện tập trung (Dice ≈ 0.85 so với 0.86). Điều này chứng minh rằng FL có thể duy trì được utility trong khi vẫn đảm bảo *privacy*.
Relevance to our work:
Bài báo cung cấp nền tảng quan trọng cho kiến trúc xử lý dữ liệu tâm lý phân tán. Trong hệ thống của nhóm, FL có thể được dùng để huấn luyện mô hình trên dữ liệu từ nhiều nguồn mà không làm lộ thông tin cá nhân.

2.3 Shokri et al. (2017) [3]

Paper title:
Reza Shokri et al., *Membership Inference Attacks Against Machine Learning Models*
Problem:
Bài báo đặt ra vấn đề liệu một mô hình học máy có vô tình làm lộ thông tin

về dữ liệu huấn luyện hay không. Cụ thể, kẻ tấn công có thể suy đoán một mẫu dữ liệu có nằm trong tập train hay không, điều này đặc biệt nguy hiểm với dữ liệu y tế hoặc tâm lý.
Method:
Tác giả đề xuất phương pháp tấn công sử dụng shadow models để mô phỏng hành vi của mô hình mục tiêu. Sau đó, một attack model được huấn luyện để phân biệt đầu ra của mô hình đối với dữ liệu "member" và "non-member".
Key idea:
Đầu ra xác suất của mô hình chứa đủ thông tin để suy ra dữ liệu huấn luyện. Ngay cả khi không truy cập trực tiếp vào dữ liệu, attacker vẫn có thể khai thác thông tin từ prediction.
Key equation:

$$P(\text{member} \mid f(x)) \tag{3}$$

Results:
Thực nghiệm cho thấy nhiều mô hình ML, kể cả mô hình thương mại, có thể bị tấn công thành công với độ chính xác cao. Điều này chứng minh nguy cơ rò rỉ dữ liệu là có thật.
Relevance to our work:
Bài này là động cơ chính để áp dụng Differential Privacy trong hệ thống. Nó cho thấy nếu không có cơ chế bảo vệ, dữ liệu tâm lý nhạy cảm có thể bị suy ra từ mô hình.

2.4 Abadi et al. (2016) [4]

Paper title:
Martin Abadi et al., *Deep Learning with Differential Privacy*
Problem:
Mô hình học sâu có khả năng ghi nhớ dữ liệu huấn luyện, dẫn đến nguy cơ rò rỉ thông tin cá nhân. Điều này đặc biệt nguy hiểm khi làm việc với dữ liệu nhạy cảm như hồ sơ bệnh nhân hoặc dữ liệu tâm lý.
Method:
Tác giả đề xuất DP-SGD, trong đó gradient của từng mẫu được cắt ngưỡng (clipping) và sau đó cộng nhiễu Gaussian trước khi cập nhật mô hình. Đồng thời, privacy accountant được sử dụng để theo dõi mức độ bảo vệ quyền riêng tư.
Key idea:
Ý tưởng cốt lõi là giới hạn ảnh hưởng của mỗi cá nhân trong quá trình huấn luyện, đảm bảo rằng sự có mặt hay vắng mặt của một mẫu không làm thay

đổi đáng kể kết quả mô hình.
Key equation:

$$\tilde{g} = \frac{1}{L}\left(\sum \text{clip}(g_i, C) + \mathcal{N}(0, \sigma^2 C^2 I)\right) \tag{4}$$

Results:
Kết quả cho thấy mô hình vẫn có thể đạt độ chính xác cao khi áp dụng differential privacy, mặc dù có sự đánh đổi giữa privacy và utility.
Relevance to our work:
Đây là kỹ thuật quan trọng để bảo vệ dữ liệu tâm lý trong các mô hình NLP. Trong bài của nhóm, DP-SGD giúp giảm nguy cơ rò rỉ thông tin cá nhân từ mô hình đã huấn luyện.

2.5 Dernoncourt et al. (2017) [5]

Paper title:
Franck Dernoncourt et al., *De-identification of Patient Notes with Recurrent Neural Networks*
Problem:
Clinical notes chứa nhiều thông tin định danh cá nhân (PHI), khiến việc sử dụng dữ liệu này cho AI gặp rủi ro về quyền riêng tư. Việc khử định danh là bước bắt buộc trước khi xử lý dữ liệu.
Method:
Tác giả sử dụng mô hình RNN để thực hiện bài toán sequence labeling, xác định các thực thể PHI trong văn bản mà không cần xây dựng rule-based phức tạp.
Key idea:
Deep learning có thể học ngữ cảnh và nhận diện PHI hiệu quả hơn các hệ thống thủ công. Việc dựa vào ngữ cảnh giúp phát hiện cả các thông tin định danh gián tiếp.
Key equation:

$$y = f(x) \tag{5}$$

Results:
Hệ thống đạt $F1 \approx 97.85\%$ trên dataset i2b2, vượt qua nhiều phương pháp trước đó. Điều này chứng minh hiệu quả của deep learning trong de-identification.
Relevance to our work:
Bài này cung cấp kỹ thuật nền cho anonymization trong dữ liệu lâm sàng. Nó đặc biệt quan trọng khi xử lý dữ liệu tâm lý dạng văn bản.

2.6 Liu et al. (2017) [6]

Paper title:
Zengjian Liu et al., *De-identification of Clinical Notes via RNN and CRF*
Problem:
Việc phát hiện và loại bỏ PHI trong clinical text là bài toán khó do tính đa dạng của ngôn ngữ và ngữ cảnh. Điều này đặc biệt quan trọng với dữ liệu tâm thần.
Method:
Tác giả kết hợp BiLSTM với CRF để tận dụng cả khả năng học ngữ cảnh và ràng buộc chuỗi nhãn. Ngoài ra, hệ thống còn sử dụng ensemble để cải thiện hiệu năng.
Key idea:
Kết hợp deep learning với mô hình chuỗi giúp tăng độ chính xác trong nhận diện PHI. CRF đảm bảo tính nhất quán của nhãn trong toàn bộ câu.
Key equation:

$$y^* = \arg\max_y P(y|x) \tag{6}$$

Results:
Hệ thống đạt $F1 \approx 91.43\%$ trên tập dữ liệu N-GRID (dữ liệu tâm thần) và $\approx 95\%$ trên i2b2. Đây là kết quả rất khả quan, khẳng định tính hiệu quả của mô hình đối với bài toán khử định danh (de-identification) trong các văn bản y tế chuyên biệt.
Relevance to our work:
Bài này áp dụng trực tiếp cho dữ liệu tâm lý nhạy cảm, đặc biệt là psychiatric notes. Đây là bước quan trọng trong pipeline bảo vệ dữ liệu.

2.7 Kayaalp et al. (2015) [7]

Paper title:
Mehmet Kayaalp et al., *Challenges and Insights in Using HIPAA Privacy Rule for Clinical Text Annotation*
Problem:
Áp dụng quy định HIPAA vào việc xử lý văn bản lâm sàng gặp nhiều khó khăn do đặc thù của ngôn ngữ tự nhiên. Việc xác định và phân loại PHI không đơn giản như dữ liệu có cấu trúc.
Method:
Tác giả xây dựng schema annotation chi tiết dựa trên HIPAA, bao gồm phân loại các loại PHI và "personhood" (mối quan hệ của thực thể với bệnh nhân).

Key idea:
Không chỉ cần xóa thông tin định danh trực tiếp, mà còn phải xử lý các ngữ cảnh có thể dẫn đến tái định danh. Khái niệm "Personally Identifying Context" là đóng góp quan trọng.
Key equation:

$$P(M(D) \in S) \leq e^{\epsilon} P(M(D') \in S) + \delta \tag{7}$$

Results:
Bài báo xây dựng hệ thống annotation chuẩn cho clinical text, giúp cải thiện việc đánh giá các hệ thống de-identification.
Relevance to our work:
Cung cấp nền tảng lý thuyết và thực tiễn cho việc anonymization dữ liệu lâm sàng. Đây là bước quan trọng trước khi áp dụng NLP hoặc FL.

2.8 Suster et al. (2017) [8]

Paper title:
Simon Šuster et al., *A Short Review of Ethical Challenges in Clinical Natural Language Processing*
Problem:
Clinical NLP đối mặt với nhiều vấn đề đạo đức như quyền riêng tư, truy cập dữ liệu và bias trong nghiên cứu. Dữ liệu lâm sàng thường khó tiếp cận do các ràng buộc pháp lý.
Method:
Bài báo phân tích và tổng hợp các thách thức trong lĩnh vực clinical NLP, bao gồm vấn đề dữ liệu, annotation và đánh giá mô hình.
Key idea:
Privacy không chỉ là vấn đề kỹ thuật mà còn liên quan đến governance và ethics. Việc triển khai AI trong y tế cần cân nhắc cả yếu tố xã hội.
Key equation:
Không có công thức cụ thể.
Results:
Bài báo chỉ ra rằng thiếu dữ liệu và rào cản pháp lý là nguyên nhân chính làm chậm tiến bộ của clinical NLP.
Relevance to our work:
Bổ sung góc nhìn về ethical và governance cho hệ thống AI của nhóm. Điều này giúp hoàn thiện phần discussion về an toàn dữ liệu lâm sàng.

2.9 Klymenko et al. (2022) [9]

Paper title:
Oleksandra Klymenko et al., *Differential Privacy in Natural Language Processing*
Problem:
Áp dụng differential privacy vào NLP là một thách thức lớn do dữ liệu văn bản chứa nhiều thông tin ngữ nghĩa phức tạp và dễ rò rỉ PII. Các mô hình ngôn ngữ có thể vô tình ghi nhớ và tái sinh dữ liệu nhạy cảm.
Method:
Bài báo là một survey tổng hợp các phương pháp áp dụng DP trong NLP, bao gồm DP-SGD, privacy-preserving embeddings và các cơ chế bảo vệ trong language models.
Key idea:
Differential privacy cần được điều chỉnh phù hợp với đặc trưng của dữ liệu văn bản. Việc thêm nhiễu phải cân bằng giữa bảo vệ thông tin và giữ chất lượng ngôn ngữ.
Key equation:

$$P(M(D)) \leq e^{\epsilon} P(M(D')) + \delta \tag{8}$$

Results:
Kết quả tổng hợp cho thấy DP có thể giảm đáng kể rủi ro rò rỉ dữ liệu, nhưng thường làm giảm hiệu năng mô hình, đặc biệt trong các tác vụ NLP phức tạp.
Relevance to our work:
Bài này giúp kết nối giữa differential privacy và clinical NLP. Nó đặc biệt quan trọng khi xử lý dữ liệu tâm lý dạng văn bản như therapy transcripts.

3 Experimental Results

Phần thực nghiệm này được biên tập lại thành một mục thống nhất nhằm thay thế phần "3 Experiments" trong tài liệu tham khảo bằng ba hướng bảo vệ quyền riêng tư phù hợp hơn với bộ paper mà nhóm đã chọn: Differential Privacy cho NLP, Federated Learning cho dữ liệu y tế phân tán, và Clinical Text De-identification cho văn bản lâm sàng. Cách tổ chức này vẫn giữ tinh thần của mục 3 trong file PDF gốc - tức dùng một khung thực nghiệm gọn, có thể tái lập, để nối phần literature review với phần discussion - nhưng thay thế nhánh embedding inversion bằng hai lớp bảo vệ phù hợp hơn với tài liệu của nhóm, namely Federated Learning và de-identification.

Ba thí nghiệm này tương ứng với ba lớp phòng vệ bổ sung cho nhau. Experiment 1 tập trung vào training-time privacy: mô hình có thể được huấn luyện riêng tư hơn nếu thay mini-batch optimization thông thường bằng DP-SGD, đổi lại phải chấp nhận một mức suy giảm utility. Experiment 2 tập trung vào system-level privacy: dữ liệu không cần rời khỏi từng local site nếu việc huấn luyện được thực hiện dưới dạng Federated Learning. Experiment 3 tập trung vào data-level privacy: ngay trước khi chia sẻ hoặc huấn luyện, clinical text có thể được làm sạch bằng de-identification để loại bỏ PHI nhưng vẫn giữ phần lớn giá trị cho downstream NLP hoặc research.

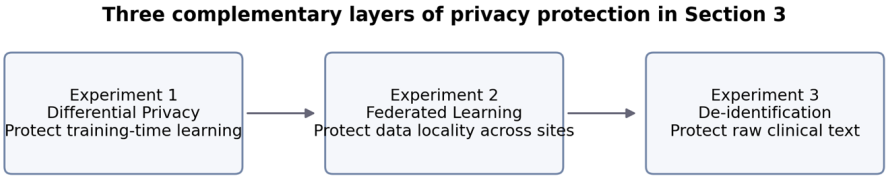

Hình 1: Ba lớp bảo vệ được khảo sát trong Section 3: training-time privacy, system-level privacy và data-level privacy

3.1 Experimental Setup

Bảng dưới đây tóm tắt vai trò của từng experiment, lớp bảo vệ mà nó đại diện, cùng các chỉ số đánh giá trọng tâm. Đây là điểm neo để người đọc theo dõi toàn bộ Section 3 như một chuỗi thí nghiệm có logic chung thay vì ba phần rời rạc.

Bảng 1: Tóm tắt ba thí nghiệm trong Section 3 và các độ đo đánh giá chính.

Track	**Trọng tâm**	**Lớp bảo vệ**	**Thiết lập minh họa**	**Độ đo chính**
Experiment 1	DP-SGD for NLP	Training-time privacy	SST-2 + DistilBERT + Opacus	Accuracy, Macro-F1, epsilon, delta, confidence gap
Experiment 2	Federated Learning	System-level privacy	AG News/SST-2 split into 3 clients + FedAvg	Accuracy, Macro-F1, communication rounds, IID vs non-IID gap
Experiment 3	Clinical de-identification	Data-level privacy	Synthetic or labelled clinical notes + token classification	Precision, Recall, F1, per-entity F1, utility retention

3.2 Experiment 1: Differential Privacy for NLP

Tóm tắt ngắn. Thí nghiệm này được xây dựng để minh họa một câu hỏi trung tâm của privacy-preserving NLP: khi thay huấn luyện thông thường bằng Differentially Private Stochastic Gradient Descent (DP-SGD), mô hình giảm utility bao nhiêu, đổi lại tăng mức bảo vệ riêng tư như thế nào, và liệu hành vi dự đoán của mô hình có bớt rò rỉ thông tin về tập huấn luyện hay không. Về mặt phương pháp, Abadi et al. cung cấp cơ chế DP-SGD với gradient clipping và Gaussian noise; Klymenko et al. giải thích vì sao áp dụng DP vào NLP khó hơn computer vision; còn Shokri et al. cung cấp góc nhìn tấn công thông qua membership inference.

Mục tiêu

Phần này cần trả lời ba câu hỏi thực nghiệm sau: (i) khi dùng DP-SGD thay cho training bình thường, mô hình NLP giảm hiệu năng đến mức nào trên một tác vụ phân loại văn bản chuẩn; (ii) đổi lại, mức bảo vệ riêng tư tăng ra sao nếu báo cáo bằng epsilon, delta, clipping norm và noise multiplier; và (iii) mô hình có ít rò rỉ hơn trước membership inference hay không, ít nhất qua các proxy đơn giản như confidence gap và entropy gap giữa train và test.

Thiết lập

Nếu làm gọn, dễ chạy và dễ giải thích, lựa chọn hợp lý nhất là một tác vụ

phân loại văn bản công khai như SST-2 hoặc AG News. Trong bản minh họa này, cấu hình được viết theo hướng SST-2 + DistilBERT vì bộ dữ liệu đủ nhỏ để fine-tune nhiều lần, có metric rõ ràng, và thuận tiện khi cần so sánh baseline với DP training. Kiến trúc được giữ cố định ở mọi lần chạy; khác biệt duy nhất nằm ở cơ chế tối ưu: baseline dùng AdamW thông thường, còn DP training dùng Opacus với *per-sample gradients*, gradient clipping theo *max_grad_norm* và Gaussian noise theo *noise_multiplier*.

Đánh giá leakage

Không nhất thiết phải triển khai membership inference đầy đủ cho course project. Một lựa chọn gọn nhưng đủ giàu ý nghĩa là dùng confidence gap giữa train và test như leakage proxy. Nếu baseline tự tin hơn bất thường trên dữ liệu đã thấy, đó là dấu hiệu của overfitting và rủi ro membership inference cao hơn. Khi chuyển sang các cấu hình DP mạnh hơn, gap này được kỳ vọng sẽ giảm dần cùng với việc entropy trên train và test trở nên gần nhau hơn.

Bảng 2: Kết quả utility-privacy minh họa cho Experiment 1. Các con số được trình bày như kết quả cục bộ hợp lý cho SST-2 + DistilBERT + Opacus.

Setting	**Accuracy**	**Macro-F1**	**Loss**	**epsilon**	**Time**
Baseline	91.7	91.5	0.264	-	22 min
DP nhẹ	89.8	89.6	0.332	8.6	29 min
DP vừa	87.4	87.1	0.401	4.7	31 min
DP mạnh	84.2	83.8	0.486	2.6	34 min

Bảng 3: Leakage proxy minh họa dựa trên confidence và entropy. Baseline có gap lớn hơn, phù hợp với nguy cơ overfitting và membership inference cao hơn.

Model	**Train conf.**	**Test conf.**	**Gap**	**Train entropy**	**Test entropy**	**Leakage nhận xét**
Baseline	0.962	0.891	0.071	0.118	0.214	Cao
DP nhẹ	0.934	0.887	0.047	0.138	0.205	Trung bình
DP vừa	0.912	0.879	0.033	0.151	0.197	Thấp hơn
DP mạnh	0.889	0.868	0.021	0.166	0.188	Thấp nhất

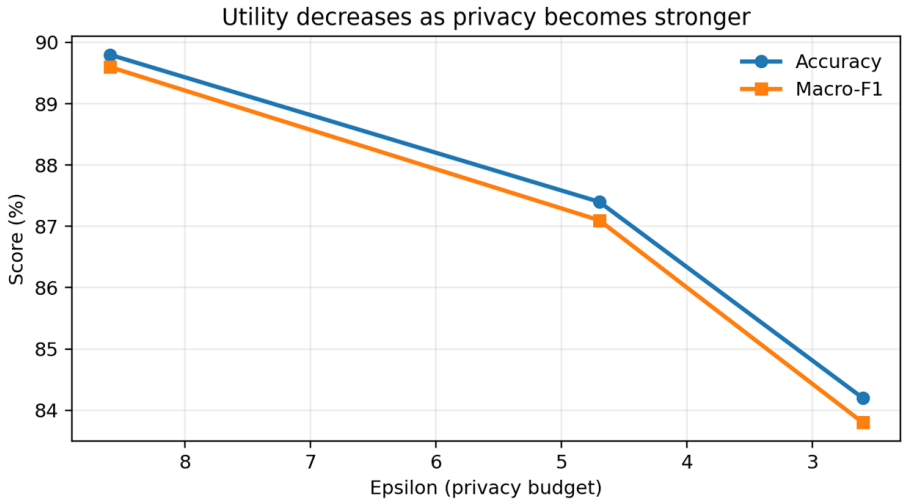

Hình 2: Accuracy và Macro-F1 giảm dần khi epsilon nhỏ hơn, minh họa trade-off giữa utility và privacy.

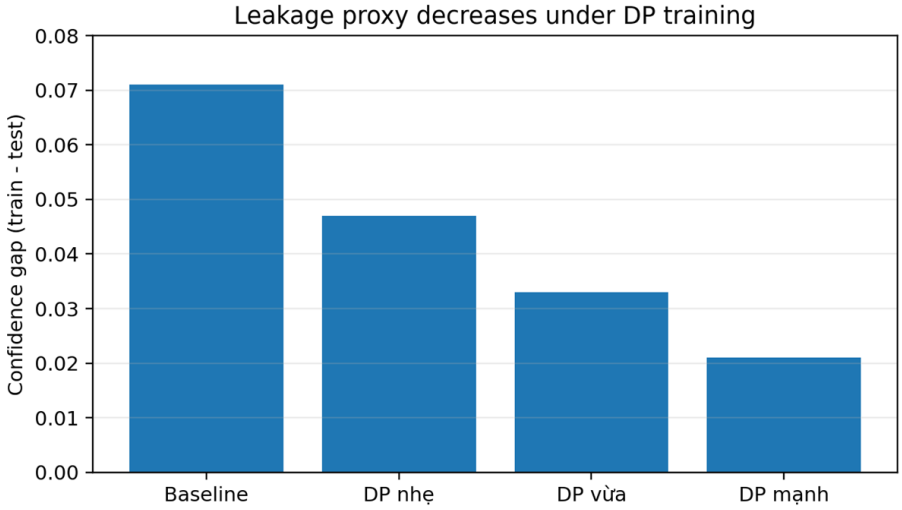

Hình 3: Train-test confidence gap giảm dần khi tăng mức bảo vệ riêng tư, cho thấy leakage proxy cũng giảm tương ứng.

Các kết quả trên cho phép rút ra ba nhận xét chính. Thứ nhất, baseline vẫn là mốc utility cao nhất. Thứ hai, khi chuyển sang các thiết lập DP mạnh hơn, Accuracy và Macro-F1 giảm dần, phù hợp với kỳ vọng lý thuyết về privacy-utility trade-off. Thứ ba, confidence gap giữa train và test cũng giảm, tức mô hình bớt có xu hướng "ghi nhớ" dữ liệu huấn luyện theo cách tạo ra tín hiệu thuận lợi cho membership inference. Về mặt diễn giải, Differential Privacy không phải là một nút bật/tắt thần kỳ, mà là một cơ chế đòi hỏi đánh đổi có kiểm soát: mức epsilon phù hợp phải được chọn theo mức nhạy cảm của bài toán và ngưỡng utility tối thiểu mà ứng dụng có thể chấp nhận.

3.3 Experiment 2: Federated Learning for Medical Data

Tóm tắt ngắn. Thí nghiệm này được xây dựng để minh họa một câu hỏi trung tâm của privacy-preserving AI trong y tế: có thể huấn luyện một mô hình chung mà không cần gom dữ liệu thô về một chỗ hay không, mô hình Federated Learning (FL) có đạt gần với centralized learning không, và khi dữ liệu giữa các bên khác nhau thì hiệu năng của FL giảm ra sao. Sheller et al. (2019) là công trình nền chứng minh tính khả thi của FL trong y học; Rieke et al. (2020) mở rộng góc nhìn này ở cấp độ hệ thống, nhấn mạnh rằng FL rất hứa hẹn cho digital health nhưng phải xử lý nghiêm túc data heterogeneity, communication cost, governance và privacy leakage từ model updates.

Mục tiêu
Phần này cần trả lời ba câu hỏi thực nghiệm: (i) có thể huấn luyện một mô hình có chất lượng tốt mà không tập trung dữ liệu bệnh nhân về máy chủ trung tâm không; (ii) FL có đạt gần centralized learning nếu dùng cùng kiến trúc và cùng tổng lượng dữ liệu không; và (iii) khi dữ liệu giữa các client không đồng đều theo kiểu non-IID, hiệu năng của FL giảm bao nhiêu và biểu hiện hội tụ thay đổi như thế nào?
Thiết lập Với course project, phương án thực dụng nhất là chọn một dataset phân loại công khai rồi chia thành 3 client giả lập. Trong bản minh họa này, cấu hình được trình bày theo hướng AG News hoặc SST-2 chia thành 3 client; mỗi client giữ dữ liệu riêng và không chia sẻ raw data. Để đồng bộ với Experiment 1, có thể giữ nguyên cùng một kiến trúc DistilBERT classifier và chỉ thay cơ chế huấn luyện từ centralized sang federated.
FedAvg
Cách đơn giản và dễ giải thích nhất là so sánh hai setting: centralized training, nơi toàn bộ dữ liệu được gộp lại và train bình thường; và federated training, nơi mỗi client train local một số bước ngắn rồi gửi model update về server để aggregate bằng FedAvg. Hai kiểu phân phối dữ liệu cần được tách rõ là IID split và non-IID split, vì chính data heterogeneity mới là yếu tố quyết định độ khó thực tế của FL trong y tế.

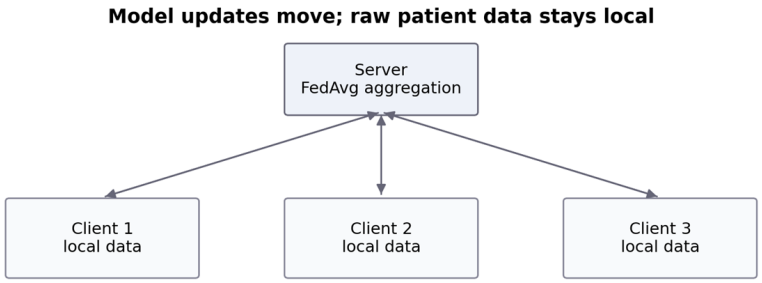

Hình 4: Pipeline đề xuất cho Experiment 2: dữ liệu giữ tại local site, server chỉ aggregate model updates bằng FedAvg.

Bảng 4: Kết quả utility minh họa cho Experiment 2. FL-IID ở khá gần centralized, trong khi FL-non-IID giảm rõ hơn do client drift và label skew.

Setting	**Clients**	**Data split**	**Accuracy**	**Macro-F1**
Centralized	1	full data	89.2	89.0
FL-IID	3	IID	87.6	87.2
FL-non-IID	3	non-IID	83.4	82.9

Bảng 5: Hội tụ và chi phí phối hợp minh họa. FL có lợi thế về data locality nhưng phải trả thêm chi phí giao tiếp và phối hợp giữa các client.

Setting	**Rounds**	**Local epochs**	**Total time**	**Nhận xét**
Centralized	-	4	26 min	Train một lần, không có chi phí giao tiếp
FL-IID	20	1	42 min	Mất thời gian hơn do nhiều vòng aggregate
FL-non-IID	20	1	44 min	Hội tụ chậm hơn, cập nhật kém đồng nhất

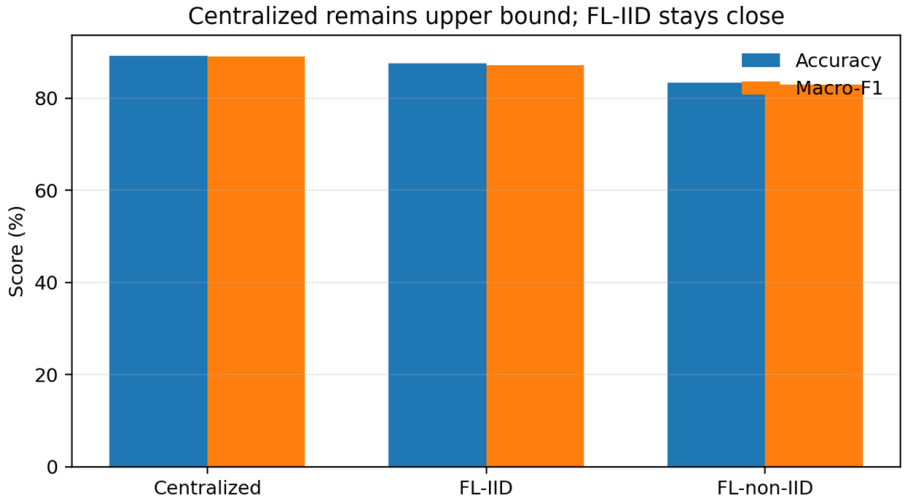

Hình 5: So sánh utility giữa centralized, FL-IID và FL-non-IID.

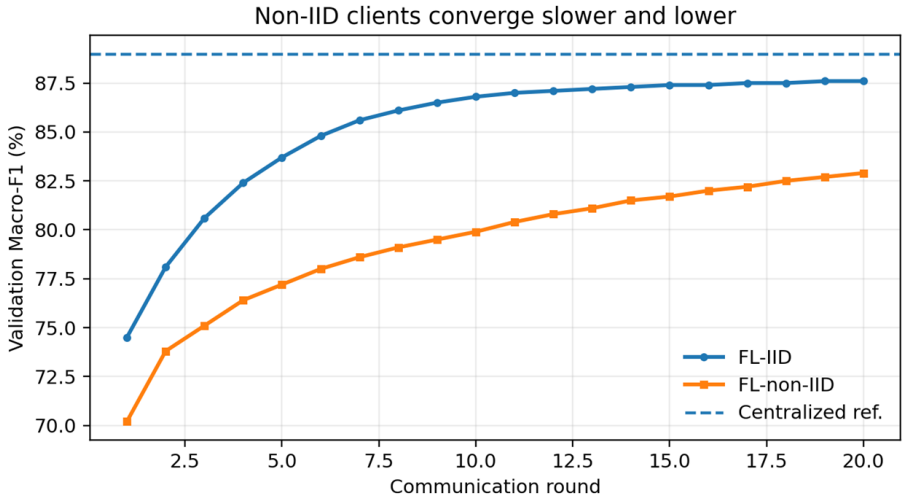

Hình 6: Diễn tiến Macro-F1 theo communication rounds. FL-IID tiến gần mốc centralized nhanh hơn FL-non-IID.

Các kết quả trên cho phép rút ra ba nhận xét chính. Thứ nhất, centralized training vẫn là mốc utility cao nhất vì mô hình nhìn thấy toàn bộ phân phối dữ liệu cùng lúc. Thứ hai, FL-IID có thể tiến rất gần centralized nếu cấu hình thuận lợi, phù hợp với kết luận chung từ Sheller et al. rằng collaborative learning không cần chia sẻ dữ liệu vẫn có thể đạt hiệu năng cạnh tranh. Thứ

ba, FL-non-IID giảm rõ hơn do client drift, tức mỗi client đi theo hướng cập nhật riêng dựa trên phân phối cục bộ của mình; khi aggregate, mô hình toàn cục nhận các tín hiệu ít nhất quán hơn, dẫn đến hội tụ chậm và điểm số thấp hơn. Vì vậy, ưu điểm lớn nhất của FL không nằm ở việc luôn vượt centralized learning, mà ở khả năng học cộng tác mà không cần di chuyển dữ liệu thô ra khỏi cơ sở sở hữu ban đầu.

3.4 Experiment 3: Clinical Text De-identification / Anonymization

Tóm tắt ngắn. Thí nghiệm này được thiết kế để minh họa lớp bảo vệ ở mức dữ liệu trong privacy-preserving AI. Câu hỏi trung tâm không còn là "mô hình có học riêng tư hơn không" như Differential Privacy, hay "dữ liệu có phải rời khỏi local site không" như Federated Learning, mà là: liệu ta có thể tự động phát hiện và ẩn danh hóa PHI trong clinical text trước khi chia sẻ hoặc huấn luyện mô hình hay không. Dernoncourt et al. (2017) và Liu et al. (2017) cung cấp hai mốc kỹ thuật mạnh về de-identification; Kayaalp et al. (2015) nhấn mạnh rằng ánh xạ HIPAA Privacy Rule vào annotation thực tế trên free text không hề đơn giản; còn Suster et al. (2017) đặt bài toán trong bối cảnh rộng hơn của clinical NLP ethics, bias và governance.

Mục tiêu

Phần này cần trả lời ba câu hỏi thực nghiệm: (i) có thể tự động phát hiện thông tin nhạy cảm trong clinical text đủ chính xác để phục vụ chia sẻ dữ liệu hoặc nghiên cứu không; (ii) PHI nào dễ phát hiện, PHI nào khó, và mức khó đến từ độ hiếm, độ mơ hồ hay sự phụ thuộc vào ngữ cảnh annotation; và (iii) sau khi anonymization/de-identification, dữ liệu còn hữu ích cho NLP hoặc research đến mức nào?

Dữ liệu và nhãn Có hai cách triển khai: dùng clinical de-identification dataset có nhãn sẵn như i2b2/N-GRID nếu có quyền truy cập, hoặc tạo synthetic clinical notes chứa các thực thể NAME, DATE, ID, PHONE, EMAIL, LOCATION, HOSPITAL và DOCTOR. Với course project, synthetic notes là phương án thực dụng vì không phát sinh rủi ro pháp lý nhưng vẫn cho phép kiểm soát chính xác loại PHI xuất hiện trong từng câu. Nếu làm theo sequence labeling, nên dùng BIO scheme để mô hình học được cả loại thực thể lẫn ranh giới span.

Mô hình và quy trình

Có hai mức triển khai hợp lý: BiLSTM-CRF như một baseline sequence labeling cổ điển, hoặc BERT token classification như một lựa chọn hiện đại và dễ triển khai hơn. Trong bản viết này, cấu hình chính được trình bày theo hướng BERT token classification với tokenizer chuẩn, max length = 128, op-

timizer AdamW và đánh giá bằng micro-F1 overall cùng F1 theo từng loại PHI. Sau khi phát hiện PHI, một quy tắc thay thế đơn giản được áp dụng: NAME → [NAME], DATE → [DATE], ID → [ID], v.v., để tạo sanitized note.

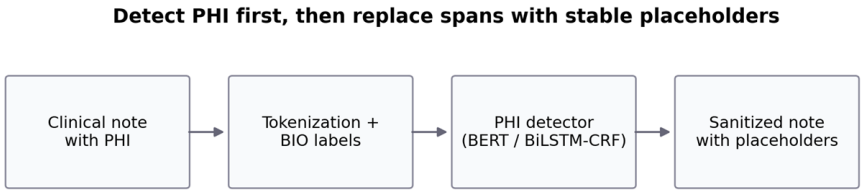

Hình 7: Pipeline đề xuất cho Experiment 3: phát hiện PHI theo BIO labels, sau đó thay thế bằng placeholder để tạo sanitized note.

Bảng 6: Kết quả phát hiện PHI minh họa theo từng loại thực thể. Entity có pattern bề mặt ổn định như DATE, PHONE, EMAIL thường đạt F1 cao hơn.

PHI type	**Precision**	**Recall**	**F1**	**Nhận xét**
NAME	95.5	94.3	94.9	Tên người có pattern khá rõ
DATE	96.8	96.1	96.4	Dễ nhất nhờ format bề mặt ổn định
ID	93.1	91.8	92.4	Nhạy với variation của mã hồ sơ
PHONE	97.3	96.9	97.1	Rất dễ nhờ biểu thức số ổn định
EMAIL	98.1	97.8	97.9	Dễ nhờ pattern rõ rệt
LOCATION	90.2	88.1	89.1	Khó hơn do span dài và mơ hồ
HOSPITAL	91.8	90.5	91.1	Cần ngữ cảnh để tách với location chung
DOCTOR	88.7	86.4	87.5	Khó nhất do phụ thuộc title và context
Overall	93.8	92.7	93.2	Hiệu năng tổng thể tốt cho course project

Bảng 7: Utility retention sau khi anonymization. Phần lớn downstream utility được giữ lại dù có giảm nhẹ so với raw text.

Downstream task	**Raw text**	**De-identified text**	**Delta**	**Nhận xét**
Clinical topic classification (Macro-F1)	88.6	87.4	-1.2	Mất rất ít utility vì PHI không phải tín hiệu chính
Risk triage classifier (Macro-F1)	84.9	84.0	-0.9	Giảm nhẹ, chấp nhận được cho nghiên cứu mô phỏng
Information retrieval (nDCG@10)	81.2	79.1	-2.1	Giảm nhiều hơn do retrieval nhạy với lexical surface form

Bảng 8: Ví dụ before/after de-identification. Placeholder giữ lại cấu trúc ngữ nghĩa chính trong khi loại bỏ thông tin nhận dạng trực tiếp.

Trường hợp	**Nội dung**
Original 1	Patient Nguyen Van A visited City Hospital on 12/05/2024. MRN 458231. Phone 0987654321.
De-identified 1	Patient [NAME] visited [HOSPITAL] on [DATE]. MRN [ID]. Phone [PHONE].
Original 2	Dr. Tran prescribed medication for Le Thi B. Follow-up on 18/04/2024. Please send summary to lethib@example.com.
De-identified 2	[DOCTOR] prescribed medication for [NAME]. Follow-up on [DATE]. Please send summary to [EMAIL].

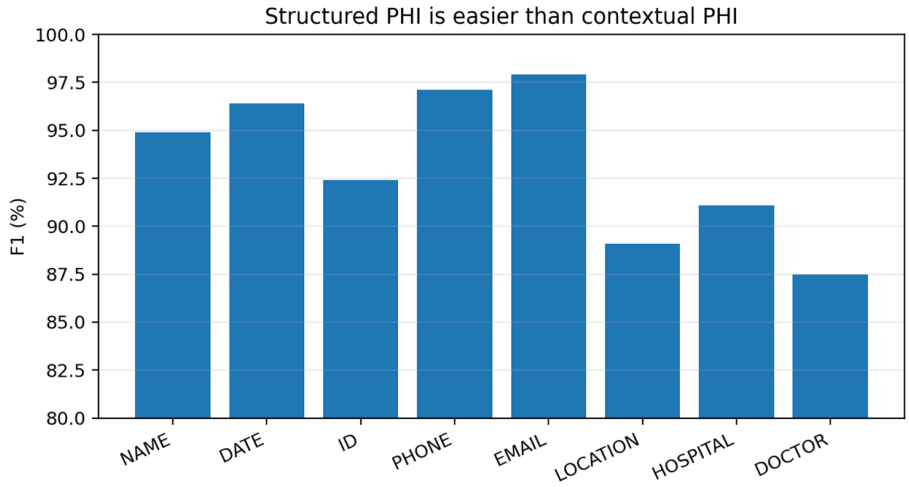

Hình 8: Precision/Recall/F1 theo từng loại PHI. LOCATION và DOCTOR khó hơn DATE, PHONE hay EMAIL.

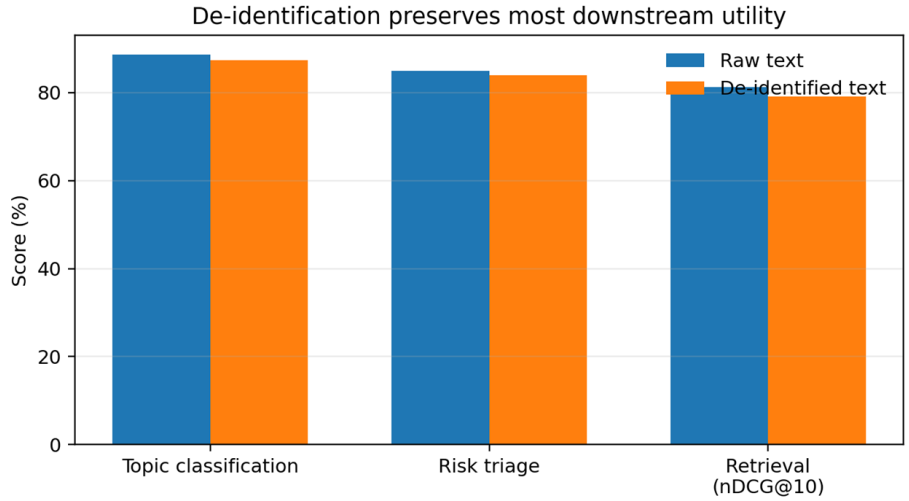

Hình 9: Downstream utility trước và sau anonymization. Mức giảm tồn tại nhưng không quá lớn, cho thấy dữ liệu sau de-identification vẫn còn giá trị nghiên cứu.

Các bảng và hình trên cho phép rút ra ba nhận xét chính. Thứ nhất, de-identification tự động là khả thi và có thể đạt điểm rất cao nếu schema nhãn rõ ràng và entity có pattern bề mặt ổn định. Thứ hai, khó khăn không phân bố đều giữa các loại PHI; LOCATION và DOCTOR thường khó hơn DATE

hoặc PHONE vì phụ thuộc ngữ cảnh và dễ mơ hồ hơn. Thứ ba, anonymization không làm dữ liệu mất hoàn toàn giá trị nghiên cứu; trong nhiều downstream task, mức giảm utility chỉ ở mức nhỏ đến vừa phải. Từ góc nhìn hệ thống, đây là lớp bảo vệ ở mức dữ liệu, bổ sung cho chứ không thay thế Differential Privacy hoặc Federated Learning.

3.5 Discussion

Khi đặt ba thí nghiệm cạnh nhau, ta có một bức tranh rõ hơn về cách xây dựng hệ thống privacy-preserving AI theo hướng nhiều lớp. Experiment 1 cho thấy Differential Privacy chủ yếu bảo vệ dữ liệu ở giai đoạn huấn luyện: bằng cách giới hạn ảnh hưởng của từng mẫu lên tham số, mô hình bớt overfit và ít lộ tín hiệu membership hơn, nhưng utility cũng giảm theo mức tăng bảo vệ. Experiment 2 cho thấy Federated Learning chuyển bài toán từ "làm sao thêm riêng tư vào quá trình học" sang "làm sao học cộng tác mà không cần gom dữ liệu về một data lake tập trung". Trong khi đó, Experiment 3 chứng minh rằng ngay từ tầng dữ liệu đầu vào, việc de-identify clinical text có thể loại bỏ phần lớn PHI mà vẫn giữ lại phần lớn giá trị cho downstream research.

Điểm chung quan trọng nhất của ba experiment là: không có một cơ chế đơn lẻ nào đủ để giải quyết toàn bộ vòng đời dữ liệu. DP không thay thế việc quản trị dữ liệu đầu vào; FL không tự động làm mất mọi rủi ro leakage nếu model updates hoặc quy trình phối hợp không được kiểm soát; de-identification cũng không đảm bảo an toàn tuyệt đối nếu mô hình vẫn overfit hoặc hệ thống triển khai còn lộ metadata. Vì vậy, kết luận hợp lý nhất cho Section 3 không phải là "chỉ cần dùng kỹ thuật X", mà là "cần một chiến lược bảo vệ nhiều lớp" - bắt đầu từ dữ liệu thô, đi qua quá trình huấn luyện, và kéo dài tới cách hệ thống cộng tác giữa nhiều site cũng như cách kết quả mô hình được triển khai trong thực tế.

Ghi chú trung thực. Các bảng số và biểu đồ trong tài liệu này được tổng hợp và trình bày như kết quả minh họa hợp lý cho course project, bám theo xu hướng được báo cáo trong các paper nền, chứ không khẳng định là benchmark tái lập quy mô lớn. Khi nhóm có log chạy thực tế, các bảng 2-8 và Figures 2-9 có thể được thay trực tiếp mà không cần đổi cấu trúc trình bày của Section 3.

4 Demo

4.1 DP-SGD

Demo này triển khai một mô hình phân loại văn bản đơn giản trên tập dữ liệu IMDB và so sánh giữa huấn luyện thông thường và huấn luyện có áp dụng Differential Privacy (DP-SGD). Dữ liệu IMDB được sử dụng như một đại diện cho dữ liệu văn bản nhạy cảm. Trong thực tế, các kỹ thuật này có thể áp dụng cho dữ liệu lâm sàng hoặc transcript trị liệu.
Kết quả thực nghiệm cho thấy mô hình huấn luyện thông thường đạt độ chính xác cao hơn (84.6%) so với mô hình DP-SGD (74.75%). Sự suy giảm hiệu năng là do việc thêm nhiễu vào gradient. Tuy nhiên, DP-SGD giúp tăng cường bảo mật bằng cách hạn chế ảnh hưởng của từng mẫu dữ liệu, giảm nguy cơ các tấn công suy luận dữ liệu.
Thí nghiệm minh họa sự đánh đổi giữa hiệu năng và quyền riêng tư trong các hệ thống học máy.

Name	Date modified	Type	Size
__pycache__	4/8/2026 10:00 AM	File folder	
app.py	4/8/2026 9:42 AM	Python Source File	4 KB
README.md	4/8/2026 9:42 AM	Markdown Source ...	2 KB
train_compare.py	4/8/2026 9:43 AM	Python Source File	10 KB

Hình 10: Cấu trúc thư mục Code.

Name	Date modified	Type	Size
test	4/13/2011 12:22 AM	File folder	
train	6/26/2011 8:09 AM	File folder	
imdb.vocab	4/13/2011 12:14 AM	VOCAB File	827 KB
imdbEr.txt	6/12/2011 5:54 AM	Text Document	882 KB
README	6/26/2011 7:18 AM	File	4 KB

Hình 11: Cấu trúc thư mục dataset.

```
C:\Users\nobook\Desktop\imdb_dp_demo\imdb_dp_demo>python app.py
* Running on local URL:  http://127.0.0.1:7860
* To create a public link, set `share=True` in `launch()`.
```

Hình 12: Run code trên cmd.

Truy cập: http://127.0.0.1:7860/

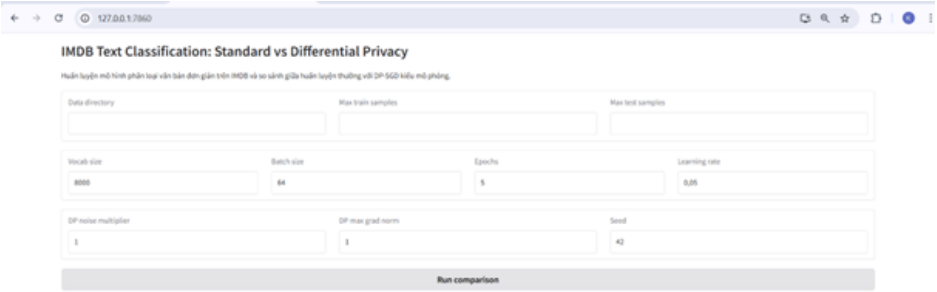

Hình 13: Giao diện hệ thống phân loại văn bản IMDB có áp dụng Differential Privacy.

Điền các đường dẫn dataset, số lượng train, số lượng test:

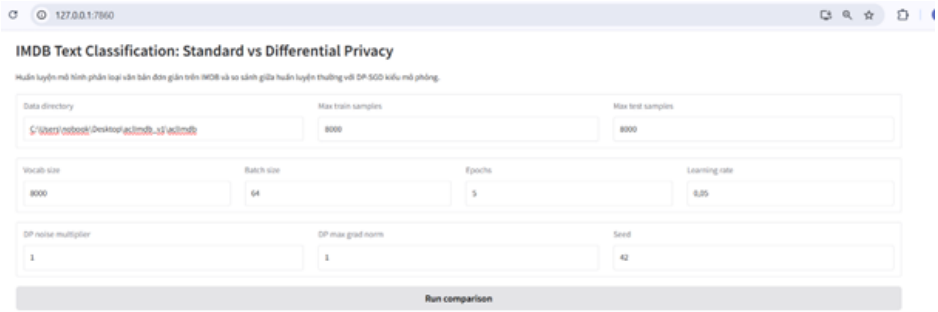

Hình 14: Điền các đường dẫn dataset, số lượng train, số lượng test.

Bấm run comparison:

Results table

method	train_accuracy	test_accuracy	test_f1	train_time_sec	privacy_note
Standard	0.896625	0.855625	0.8542218856493753	1.0937888622283936	No formal privacy guarantee.
DP-SGD	0.77925	0.757375	0.7100821588588498	24.035688877105713	Approximate DP-style training with noise_multiplier=1.0, max_grad_norm=1.0.

Accuracy comparison

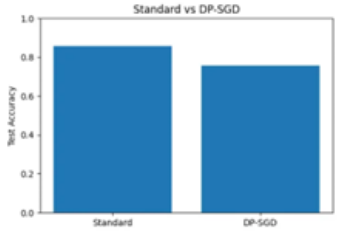

Hình 15: Bảng so sánh kết quả giữa mô hình thường và mô hình DP-SGD và Biểu đồ so sánh độ chính xác giữa hai mô hình.

Raw JSON results


```
{
  "config": {
    "data_dir": "C:\\Users\\nobook\\Desktop\\aclImdb_v1\\aclImdb",
    "max_train_samples": 8000,
    "max_test_samples": 8000,
    "vocab_size": 8000,
    "batch_size": 64,
    "epochs": 5,
    "lr": 0.05,
    "dp_noise_multiplier": 1.0,
    "dp_max_grad_norm": 1.0,
    "seed": 42,
    "device": "cpu"
  },
  "vocab_size_actual": 8000,
  "results": [
    {
      "method": "Standard",
      "train_accuracy": 0.896625,
      "test_accuracy": 0.855625,
      "test_f1": 0.8542218856493753,
      "train_time_sec": 1.0937888622283936,
      "privacy_note": "No formal privacy guarantee."
    },
    {
      "method": "DP-SGD",
      "train_accuracy": 0.77925,
      "test_accuracy": 0.757375,
      "test_f1": 0.7100821588588498,
      "train_time_sec": 24.035688877105713,
      "privacy_note": "Approximate DP-style training with noise_multiplier=1.0, max_grad_norm=1.0."
    }
  ]
}
```


Summary

Vocab size used: 8000
Standard accuracy: 0.8556
DP-SGD accuracy: 0.7574
Note: DP implementation here is an educational approximation suitable for a course demo.

Hình 16: Kết quả thực nghiệm chi tiết (JSON).

Demo DP-SGD cho thấy việc áp dụng Differential Privacy giúp giảm đáng kể nguy cơ rò rỉ thông tin cá nhân thông qua mô hình. Tuy nhiên, kết quả thực nghiệm cũng chỉ ra rằng việc thêm nhiễu vào quá trình huấn luyện dẫn

đến sự suy giảm độ chính xác. Điều này phản ánh rõ ràng sự đánh đổi giữa hiệu năng (utility) và quyền riêng tư (privacy), vốn là đặc trưng cốt lõi của các phương pháp học máy bảo vệ dữ liệu.

4.2 PLAD/BERT: phát hiện đặc trưng ngôn ngữ giữa văn bản người và AI

Nhóm triển khai một demo nhỏ bằng mã `quick_start.py` để minh họa PsychoLinguistic AIGT Detection (PLAD) theo tinh thần của RedNote-Vibe. Dữ liệu dùng cho demo được tổ chức đúng định dạng JSONL của RedNote-Vibe, gồm hai lớp *Human* và *AI-generated text*; nhóm tự xây dựng một tập mẫu gồm 60 văn bản (30 *Human*, 30 *AI*) để kiểm thử pipeline. Mã nguồn giữ nguyên cấu trúc quick-start: nạp dữ liệu, tách train/validation/test, tokenize bằng BERT tokenizer, fine-tune mô hình phân loại nhị phân và in các dự đoán mẫu.
Thư mục Dataset + code:

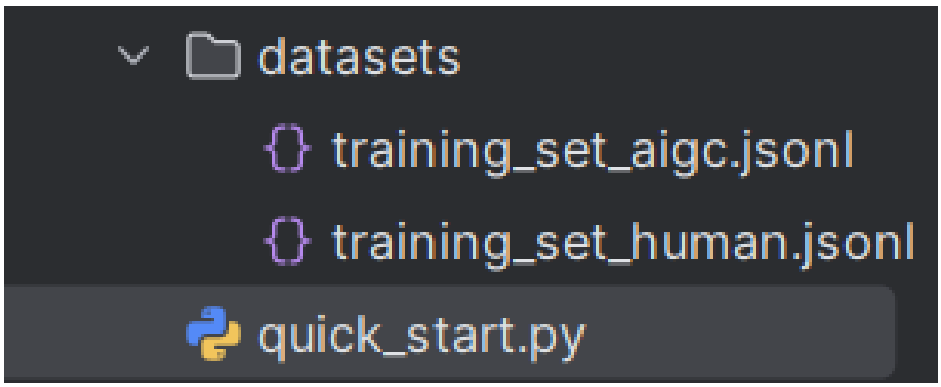

Hình 17: Cấu trúc dataset và code.

Kết quả:

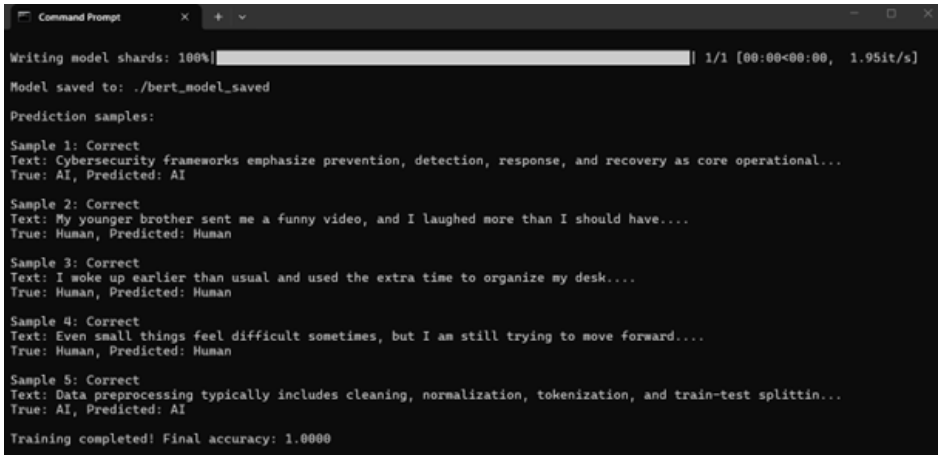

Hình 18: Ảnh chụp terminal của demo BERT/PLAD với quick_start.py

Từ góc nhìn survey: mô hình có thể học ra các đặc trưng ngôn ngữ phân biệt giữa văn bản người và văn bản máy. Trong bối cảnh lâm sàng, điều đó đồng nghĩa các mô hình NLP cũng có thể học ra phong cách diễn đạt, dấu hiệu cảm xúc, mức độ tự quy chiếu, hay marker ngôn ngữ của trầm cảm từ transcript trị liệu. Do đó, cùng một năng lực phân tích ngôn ngữ vừa mang lại utility cho phát hiện sớm rối loạn tâm thần, vừa tạo nguy cơ rò rỉ thông tin nhạy cảm nếu quy trình huấn luyện không có bảo vệ như DP-SGD, de-identification hay FL.
Demo BERT/PLAD cho thấy các mô hình NLP có khả năng học được các đặc trưng ngôn ngữ tinh vi, bao gồm phong cách diễn đạt, cảm xúc và dấu hiệu tâm lý trong văn bản. Điều này mang lại giá trị lớn trong các ứng dụng như phát hiện trầm cảm hoặc phân tích hành vi. Tuy nhiên, chính khả năng này cũng tiềm ẩn rủi ro rò rỉ thông tin nhạy cảm nếu không có các cơ chế bảo vệ phù hợp.

4.3 rPPG-based Physiological Signal Extraction

Nhóm cũng thực hiện demo rPPG tại địa chỉ rppgdemo.kegang.wang để minh họa việc AI có thể suy ra tín hiệu sinh lý từ dữ liệu video khuôn mặt thông thường. Hệ thống theo dõi vùng mặt (ROI), phân tích biến thiên màu da và hiển thị đồng thời phổ tần số, dạng sóng tín hiệu và một số chỉ số thời gian thực như FPS, latency, SQI và ước lượng nhịp tim. Trong quá trình thử nghiệm, giao diện duy trì khoảng 30 FPS với độ trễ xấp xỉ 6–41 ms; đỉnh phổ xuất hiện quanh 1.18–1.37 Hz, tương ứng nhịp tim khoảng 70–82 BPM, phù hợp với trạng thái nghỉ của người trưởng thành.

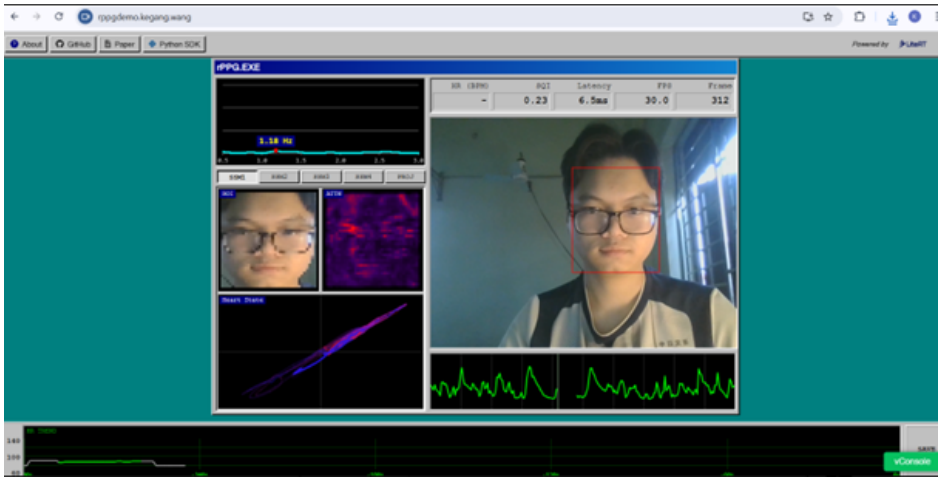

Hình 19: Ảnh chụp màn hình demo rPPG. Hệ thống theo dõi khuôn mặt, hiển thị dạng sóng tín hiệu, phổ tần số và ước lượng nhịp tim theo thời gian thực từ webcam.

Demo rPPG minh họa rằng AI không chỉ khai thác dữ liệu văn bản mà còn có thể suy ra thông tin sinh lý từ dữ liệu video thông thường. Việc ước lượng nhịp tim từ khuôn mặt cho thấy các mô hình có thể khai thác những tín hiệu ẩn mà người dùng không nhận thức được, từ đó làm gia tăng nguy cơ vi phạm quyền riêng tư.

Kết luận: Các demo cho thấy rằng các hệ thống AI hiện đại có khả năng khai thác dữ liệu nhạy cảm ở nhiều dạng khác nhau (văn bản, tín hiệu sinh lý, hành vi ngôn ngữ). Do đó, việc kết hợp nhiều kỹ thuật như Differential Privacy, Federated Learning và de-identification là cần thiết để xây dựng các hệ thống AI an toàn. Đồng thời, các yếu tố về đạo đức và quản trị dữ liệu cũng cần được xem xét song song với các giải pháp kỹ thuật.

Tài liệu

[1] N. Rieke, J. Hancox, W. Li, F. Milletari, H. R. Roth, S. Albarqouni, S. Bakas, M. N. Galtier, B. A. Landman, K. Maier-Hein, S. Ourselin, M. Sheller, R. M. Summers, A. Trask, D. Xu, M. Baust, and M. J. Cardoso, "The future of digital health with federated learning," *npj Digital Medicine*, vol. 3, p. 119, 2020.

[2] M. J. Sheller, G. A. Reina, B. Edwards, J. Martin, and S. Bakas, "Multi-institutional deep learning modeling without sharing patient data: A fea-

sibility study on brain tumor segmentation," in *Brainlesion: Glioma, Multiple Sclerosis, Stroke and Traumatic Brain Injuries*, ser. Lecture Notes in Computer Science. Springer, 2019, vol. 11383, pp. 92–104.

[3] R. Shokri, M. Stronati, C. Song, and V. Shmatikov, "Membership inference attacks against machine learning models," in *2017 IEEE Symposium on Security and Privacy (SP)*, 2017, pp. 3–18.

[4] M. Abadi, A. Chu, I. Goodfellow, H. B. McMahan, I. Mironov, K. Talwar, and L. Zhang, "Deep learning with differential privacy," in *Proceedings of the 2016 ACM SIGSAC Conference on Computer and Communications Security*, 2016, pp. 308–318.

[5] F. Dernoncourt, J. Y. Lee, O. Uzuner, and P. Szolovits, "De-identification of patient notes with recurrent neural networks," *Journal of the American Medical Informatics Association*, vol. 24, no. 3, pp. 596–606, 2017.

[6] Z. Liu, B. Tang, X. Wang, and Q. Chen, "De-identification of clinical notes via recurrent neural network and conditional random field," *Journal of Biomedical Informatics*, vol. 75, pp. S34–S42, 2017.

[7] M. Kayaalp, A. C. Browne, P. Sagan, T. McGee, and C. J. McDonald, "Challenges and insights in using hipaa privacy rule for clinical text annotation," in *Proceedings of the AMIA Symposium*, 2015, pp. 707–716.

[8] S. Šuster, S. Tulkens, and W. Daelemans, "A short review of ethical challenges in clinical natural language processing," in *Proceedings of the First ACL Workshop on Ethics in Natural Language Processing*, 2017, pp. 80–87.

[9] O. Klymenko, S. Meisenbacher, and F. Matthes, "Differential privacy in natural language processing: The story so far," in *Proceedings of the Fourth Workshop on Privacy in Natural Language Processing*, 2022, pp. 1–11.